Wpływ funkcji pewności na jakość rekomendacji gier w modelu implicit ALS

Michał Tałałaj

Wydział Matematyki i Nauk Informacyjnych
Politechnika Warszawska

promotor: dr inż. Robert Małysz

27 września 2026

Motywacja

- W systemach rekomendacyjnych rzadko dysponujemy jawnymi ocenami. Dostępne są jedynie ślady zachowań, takie jak kliknięcia, zakupy czy czas interakcji.
- Model implicit ALS rozdziela taki sygnał na dwie części:
  - czy wystąpiła interakcja – p_{ui},
  - jak bardzo ufamy tej obserwacji – c_{ui}.
- Postać funkcji c_{ui} decyduje o tym, w jakim stopniu model różnicuje obserwacje o różnej intensywności.

Luka badawcza

Wybór tej funkcji bywa przyjmowany jako założenie, bez porównania jej różnych postaci i weryfikacji, czy różnicowanie wag poprawia jakość rekomendacji.

Pytania badawcze

PB1 Czy sposób przekształcenia czasu gry na wagi pewności wpływa na jakość rekomendacji?

PB2 Czy różnicowanie wag według czasu gry przewyższa wariant o stałej wadze?

PB3 Jak wybór funkcji pewności wpływa na miary wykraczające poza trafność oraz czy poprawa trafności odbywa się kosztem innych aspektów jakości?

PB4 Który czynnik ma większy wpływ na wyniki: sposób ważenia obserwacji czy klasa modelu?

Porównywane modele

implicit ALS

- podejście punktowe
- minimalizacja ważonego błędu kwadratowego
- pięć wariantów c_{ui}

BPR

- podejście parowe
- maksymalizacja prawdopodobieństwa poprawnego uporządkowania
- sygnał binarny

Popularność

- punkt odniesienia
- brak personalizacji
- brak hiperparametrów

Wszystkie modele dostrojono niezależnie i oceniono na tym samym zbiorze testowym.

Badane funkcje pewności

$c_{ui} = 1 + \alpha r_{ui}$	liniowa *(Hu i in.)*
$c_{ui} = 1 + \alpha \log(1 + r_{ui})$	logarytmiczna *(Hu i in.)*
$c_{ui} = 1 + \alpha \frac{\log(1 + r_{ui})}{1 + \log(1 + r_{ui})}$	z saturacją *(własna)*
$c_{ui} = 1 + \alpha \log(1 + r_{ui} + \beta)$	z przesunięciem β *(własna)*
$c_{ui} = 1 + \gamma$	stała *(warunek kontrolny)*

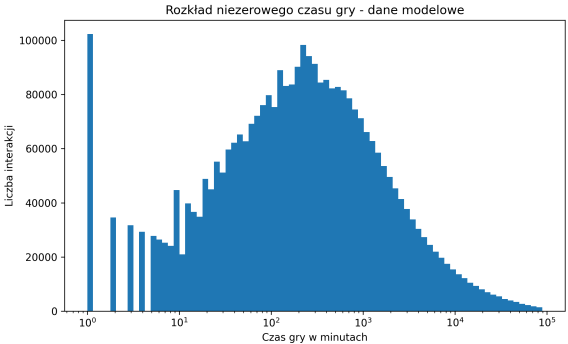
Uporządkowane według malejącego stopnia różnicowania sygnału.

Dane

Steam (kolekcja J. McAuleya)

interakcje	5 132 610
użytkownicy	62 944
gry	9 198
gęstość	0,00887

- mediana czasu gry: **35 min**
- **ok. 1/3** interakcji z zerowym czasem gry



Rozkład dodatniego czasu gry (skala logarytmiczna)

Przebieg badania

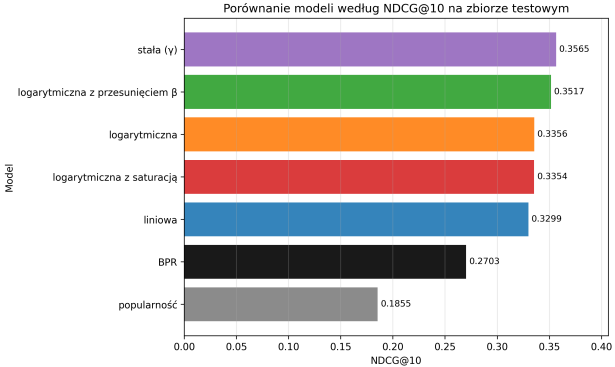
Przygotowanie i strojenie

- filtracja: min. 5 gier / 5 użytkowników
- podział 81/9/10 losowo w profilu użytkownika
- Optuna (TPE), 150 prób na wariant

Ewaluacja (listy długości 10)

- trafność: precyzja, pełność, NDCG
- poza trafnością: pokrycie katalogu, ILD, ΔGAP
- stabilność: 5 podziałów, 5 inicjalizacji
- test Wilcoxona + korekta Holma-Bonferroniego
- bootstrap: 5000 powtórzeń, 95% CI

Wynik główny



- Najwyższą trafność osiąga wariant **o stałej funkcji pewności** (0,3565).
- Poprawa: **+6,2%** wzgl. logarytmicznego, **+8,1%** wzgl. liniowego.

Istotność statystyczna i wielkość efektu

- Test Wilcoxona, 10 porównań parowych, korekta Holma-Bonferroniego. **Wszystkie różnice istotne** na poziomie 0,05.
- Duża liczba obserwacji ($n = 62\,944$) sprawia, że istotne są także niewielkie różnice, dlatego wyznaczono wielkość efektu metodą bootstrapu.

Porównanie	średnia różnica NDCG@10	95% CI
stała vs liniowa	0,0266	[0,0248; 0,0284]
stała vs z przesunięciem β	0,0049	[0,0045; 0,0052]
log. vs log. z saturacją	−0,0002	[−0,0003; −0,0001]

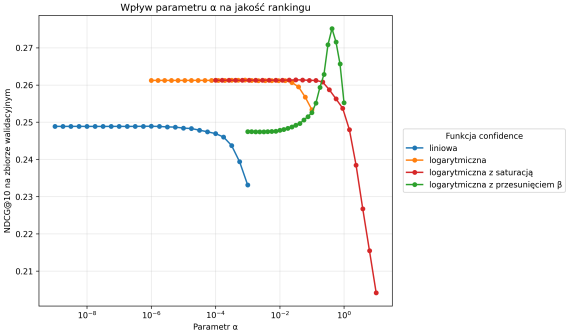
Czego nie widać bez warunku kontrolnego

Problem

Kolejne przekształcenia dawały coraz lepsze wyniki. Nie wiadomo jednak, czy poprawa wynika z lepszego odwzorowania siły preferencji, czy z czegoś innego.

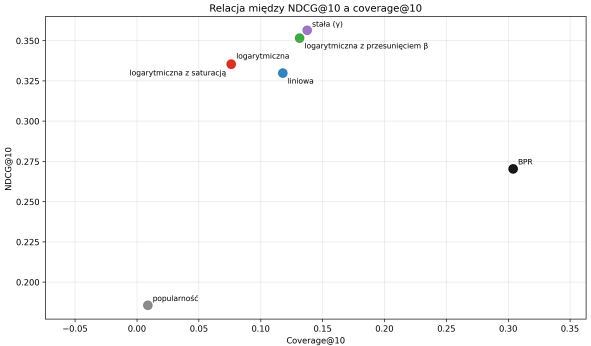
- Wariant z przesunięciem β zmienia **dwie rzeczy naraz**: podnosi poziom bazowy pewności i kompresuje różnice między obserwacjami.
- Oba efekty sterowane są **tym samym parametrem**, więc nie da się ustalić, któremu z nich przypisać poprawę.
- Rozstrzyga dopiero przypadek graniczny: funkcja, która **całkowicie pomija** czas gry, czyli oryginalny wzór $c_{ui} = 1 + \alpha r_{ui}$ zastosowany do sygnału $r_{ui} \in \{0, 1\}$.

Diagnoza: przekształcenia zapadają się do postaci binarnej



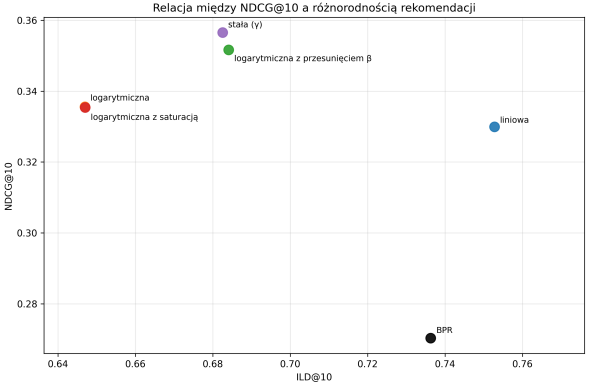
- Dla wszystkich wariantów poza tym z β optimum leży przy $\alpha \to 0$, strojenie samo usuwa różnicowanie wag.
- Wariant z β tylko pozornie stanowi wyjątek, przy $\beta = 108{,}3$ pewność rośnie od $c(0) = 2{,}83$ zaledwie do $c(35) = 2{,}94$.

Pokrycie katalogu



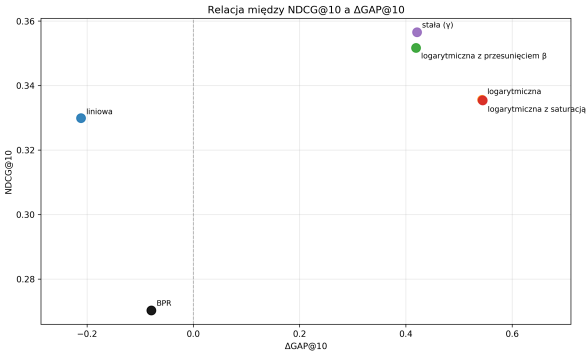
- **Brak kompromisu wewnątrz rodziny ALS** – czołowe warianty mają jednocześnie najwyższe pokrycie.
- BPR: **0,3039** – ponad dwukrotnie większe niż najlepszy ALS, kosztem trafności.

Różnorodność wewnątrzlistowa



- BPR: wysoka różnorodność (0,7363) przy najniższej trafności wśród modeli faktoryzacji.
- Wewnątrz ALS wartości rosną z liczbą czynników ukrytych, ale sam wymiar nie przesądza – BPR przy $f = 96$ ustępuje wariantowi liniowemu przy $f = 80$.

Obciążenie popularnością



- $\Delta\text{GAP} = 0$ oznacza zgodność popularności rekomendacji z profilem użytkownika.
- Wariant liniowy i BPR: wartości ujemne. Możliwe wyjaśnienia: większa wymiarowość i słabsza regularyzacja albo po prostu słabsze dopasowanie.

Model popularnościowy ($\Delta\text{GAP} = 1{,}42$) pominięto dla czytelności.

Odpowiedzi na pytania badawcze

PB1 Tak, ale w kierunku odwrotnym do oczekiwanego – najlepiej wypadają przekształcenia słabiej uzależnione od czasu gry.

PB2 Nie. Wariant stały osiąga najwyższą trafność w badanym zbiorze.

PB3 Niewielkie kompromisy wewnątrz rodziny ALS, ujawniają się dopiero przy zmianie klasy modelu.

PB4 Różnice między klasami modeli są kilkukrotnie większe niż te wewnątrz rodziny ALS.

Ograniczenia i kierunki dalszych badań

Ograniczenia

- jeden zbiór danych
- warianty dostrojone niezależnie – różnią się też f i λ
- sygnał: czas akumulowany przez cały okres posiadania
- ewaluacja offline

Dalsze badania

- **funkcje niemonotoniczne** – krótka rozgrywka może być sygnałem *negatywnym*
- rozdzielenie poziomu bazowego od członu zależnego od czasu gry
- normalizacja względem typowego czasu rozgrywki dla gatunku
- eksperyment przy ustalonym f dla wszystkich wariantów

Dziękuję za uwagę

Zapas: hiperparametry

Wariant	f	α	β / γ	λ
Liniowa	80	$9{,}948 \cdot 10^{-7}$	—	0,003588
Logarytmiczna	24	0,000571	—	0,130920
Log. z saturacją	24	0,024390	—	0,169714
Log. z przesunięciem β	48	0,389185	108,284	0,010565
Stała	48	—	2,364	0,057607
BPR	96	—	—	0,003237

Wszystkie warianty ALS: 30 iteracji. BPR: 150 iteracji, krok uczenia 0,001760.

Zapas: funkcja celu implicit ALS

$$\mathcal{L}_{\text{iALS}} = \sum_{u=1}^{m} \sum_{i=1}^{n} c_{ui} \left(p_{ui} - \mathbf{x}_u^T \mathbf{y}_i \right)^2 + \lambda \left(\sum_u \|\mathbf{x}_u\|_2^2 + \sum_i \|\mathbf{y}_i\|_2^2 \right)$$

Naprzemienna optymalizacja – przy ustalonej macierzy $\mathbf{Y}$:

$$\mathbf{x}_u = \left(\mathbf{Y}^T \mathbf{C}^u \mathbf{Y} + \lambda \mathbf{I}_f \right)^{-1} \mathbf{Y}^T \mathbf{C}^u \mathbf{p}^u$$

Zapas: kryterium optymalizacyjne BPR

Dla trójek $(u, i, j) \in D_S$, gdzie i to obiekt zaobserwowany, a j niezaobserwowany:

$$\hat{s}_{uij} = \mathbf{x}_u^T \mathbf{y}_i - \mathbf{x}_u^T \mathbf{y}_j$$

Maksymalizacja prawdopodobieństwa a posteriori prowadzi do kryterium:

$$\mathcal{L}_{\text{BPR}}(\Theta) = \sum_{(u,i,j) \in D_S} \ln \sigma(\hat{s}_{uij}) - \lambda_\Theta \left(\sum_u \|\mathbf{x}_u\|_2^2 + \sum_i \|\mathbf{y}_i\|_2^2 \right)$$

- Uczenie: LearnBPR – stochastyczne wznoszenie gradientu z próbkowaniem bootstrapowym.
- Brak wag pewności – model operuje wyłącznie na uporządkowaniu par, nie na intensywności interakcji.

Zapas: definicje metryk

Trafność

$$\mathrm{DCG}_u@N = \sum_{k=1}^{N} \frac{\mathbf{1}\left(i_k^{(u)} \in \mathcal{I}_u^{\text{test}}\right)}{\log_2(k+1)}$$

$$NDCG@10 = \frac{1}{|\mathcal{U}|} \sum_u \frac{\mathrm{DCG}_u@N}{\mathrm{IDCG}_u@N}$$

Pokrycie katalogu

$$\text{Coverage}@N = \frac{\left|\bigcup_u \mathcal{R}_u^N\right|}{|\mathcal{I}|}$$

Różnorodność wewnątrzlistowa

$$\mathrm{ILD}_u@N = \frac{2}{N(N-1)} \sum_{k<l} d_{\cos}\left(i_k^{(u)}, i_l^{(u)}\right)$$

odległość liczona na współwystępowaniu w macierzy **P**

Obciążenie popularnością

$$\Delta\mathrm{GAP}@N = \frac{\mathrm{GAP}_{\text{rec}}@N - \mathrm{GAP}_{\text{profile}}}{\mathrm{GAP}_{\text{profile}}}$$

GAP — średnia popularność pozycji odpowiednio na liście rekomendacji i w profilu użytkownika

Zapas: pełne wyniki testowe

Model	NDCG@10	P@10	R@10	Cov@10	ΔGAP@10	ILD@10
Popularność	0,1855	0,0965	0,1783	0,0087	1,4233	—
ALS liniowa	0,3299	0,1841	0,2642	0,1178	−0,2112	0,7528
ALS logarytmiczna	0,3356	0,1810	0,3019	0,0762	0,5433	0,6469
ALS log. z saturacją	0,3354	0,1809	0,3019	0,0761	0,5443	0,6470
ALS log. z przes. β	0,3517	0,1956	0,3338	0,1313	0,4191	0,6841
ALS stała	**0,3565**	**0,1978**	**0,3370**	**0,1374**	0,4210	0,6825
BPR	0,2703	0,1329	0,2614	**0,3039**	−0,0789	0,7363

Odchylenia standardowe metryk trafności nie przekraczają 0,2% wartości średniej.